

AI LOCAL DOC ASSISTANT

Bienvenue à notre présentation sur la surcharge documentaire et comment l'IA peut vous aider à y remédier.

Team Blue – Hackathon #2

Michel LULEV et Julianna ROMANOVA


29/07/2025

1. Contexte & Problème


La surcharge documentaire : un frein à l'information utile




80 % des documents d'entreprise sont non structurés.



Temps perdu à chercher manuellement l'information essentielle.



Difficulté à résumer **l'essentiel** rapidement et efficacement.



Besoin crucial : poser une question et obtenir une réponse ciblée.

2. Objectif du projet

Un assistant local pour interroger, résumer et exploiter vos documents



Extraction de texte

Extraire les textes des formats PDF, DOCX et TXT avec précision.



Réponses ciblées

Répondre à vos questions posées en langage naturel.



Résumés automatiques

Générer des résumés concis et pertinents.



Local et Sécurisé

Fonctionnement entièrement local, aucune donnée n'est envoyée en ligne.

3. Architecture fonctionnelle

Un pipeline IA modulaire, automatisé et robuste

1

Upload fichier

Commencez par charger vos documents dans l'application. Vous pouvez glisser-déposer des fichiers ou les sélectionner à partir de votre ordinateur.

2

Extraction texte

Une fois les fichiers importés, notre système extrait automatiquement le contenu textuel. Nous analysons le format des documents pour récupérer efficacement toutes les informations pertinentes.

3

Nettoyage & découpage

Ensuite, nous procédons à un nettoyage linguistique du texte extrait. Nous segmentons le contenu en unités de sens cohérentes pour faciliter l'analyse.

4

Vectorisation (MiniLM)

Nous utilisons un modèle de langage pré-entraîné, MiniLM, pour transformer le texte en vecteurs numériques. Cela nous permet de capturer la sémantique du contenu.

5

Indexation (FAISS)

Les vecteurs sont ensuite indexés à l'aide de la bibliothèque FAISS. Cela optimise grandement les performances de recherche et de récupération d'informations.

6

Résumé (DistilBART)

Enfin, nous générons automatiquement un résumé concis du contenu à l'aide du modèle DistilBART. Vous obtenez ainsi une synthèse rapide des informations clés.

7

Export et log

Pour terminer, vous pouvez exporter les résultats au format texte ou PDF, et consulter un historique détaillé de vos analyses.

4. Technologies utilisées

Des outils IA et NLP adaptés au traitement local rapide

Module	Technologie	Raison du choix
Extraction	pdfplumber, docx2txt	Simple, efficace et léger
Traitement	spaCy	Découpage linguistique fiable
Embeddings	MiniLM	Rapide et précis pour recherche sémantique
Indexation	FAISS	Recherche vectorielle rapide et locale
Résumé	DistilBART	Génératif, léger, pertinent pour la synthèse
Interface	Streamlit	Simple à déployer, interactive

5. Interface utilisateur

Une interface fluide pour tous les profils

Téléchargement simple de fichiers

Chargez facilement vos documents directement dans l'application, sans effort.

Résultats en temps réel

Recevez instantanément les informations dont vous avez besoin, sans attendre.

Exportation facile

Sauvegardez vos résultats au format texte ou PDF pour les consulter plus tard.

1

2

3

4


5

Interrogation naturelle

Posez vos questions en langage naturel et obtenez des réponses pertinentes.


Résumé instantané

Accédez rapidement à un résumé concis des principales informations de vos documents.



6. Automatisation intelligente

Une surveillance en temps réel pour un gain de temps total



- Détecteur vigilant** : L'application surveille sans relâche vos dossiers et signale instantanément tout nouveau fichier ajouté.
- Travail en coulisses** : Une fois lancé, le processus d'extraction, de traitement et d'analyse s'exécute discrètement en tâche de fond, vous laissant libre de vaquer à vos autres occupations.
- Résumé et partage** : Lorsque le travail est terminé, un résumé concis est automatiquement généré. Vous n'avez plus qu'à l'exporter dans le format de votre choix pour le partager ou l'archiver.
- Journal de bord** : Chaque étape du processus est soigneusement consignée dans un historique détaillé. Vous pouvez à tout moment retracer l'intégralité de votre activité.
- Alerte à la clé** : Dès que le traitement d'un document est terminé, une notification sonore vous avertit pour que vous puissiez consulter les résultats sans tarder.

7. Évaluation des performances

Le système retrouve-t-il les bons passages ?

Pour évaluer la pertinence de nos résultats, nous avons utilisé la métrique **Precision@3**

Cette métrique compare les 3 premiers résultats obtenus par notre système avec la réponse correcte attendue

- **Precision@3** : Les 3 meilleurs résultats sont-ils pertinents ?

Question	Precision@3
Types de comportement d'achat	1.00
Achat impulsif	0.66
Fidélisation client	0.33

8. Résumés et export

Un résumé intelligent, exportable et réutilisable

Résumé de haute volée : Notre puissant modèle de résumé génératif **DistilBART** analyse en profondeur les documents pour en extraire l'essence même. Grâce à ses capacités de compréhension avancées, il produit des synthèses concises et pertinentes, sans rien perdre de la substance originale.

Formats tout-terrain : Exportez les résumés générés dans les formats les plus répandus, comme **.txt** ou **.pdf**. Avec la prise en charge intégrée de l'Unicode, vous êtes assuré d'une compatibilité maximale, y compris pour les caractères spéciaux ou les langues non latines.

Horodatage malin : Chaque résumé produit est estampillé d'un horodatage précis, permettant de retracer facilement l'historique de vos documents. Vous pouvez ainsi suivre l'évolution de vos fichiers au fil du temps et vous y retrouver sans effort.

Centrale de stockage : Tous les résumés générés sont automatiquement enregistrés dans le dossier sécurisé **data/outputs/**. Vous n'avez plus à vous soucier de l'organisation de vos fichiers, tout est classé et accessible en un clin d'œil.



9. Livraison & utilisation

Un projet packagé, simple à lancer, prêt à livrer

- **launch_app.bat** : lancez tout en un seul clic, pour une mise en route simplifiée.
- **requirements.txt** : assure un environnement reproductible pour tous les utilisateurs.
- **.zip généré automatiquement** : facilite la distribution et le déploiement.
- **evaluate.py** : un outil de test intégré pour vérifier la performance.
- **.gitignore, README.md** : projet documenté avec une structure claire.

